VERSIÓN TÉCNICA · 2026-04-18 · GITHUB.COM/LEANMASTERPYMES/ENERGIA_OPTIMA

Optimización de Compras de Energía en el Sector Público: Un Modelo de IO e IA para Reducir Costos

Nota metodológica — léase antes de interpretar las cifras. Este artículo presenta un **modelo demostrativo**, no una auditoría. El marco legal, el precio ponderado 2024 (150.81 USD por megavatio-hora, MWh), el rango de contratos de suministro a largo plazo tipo Power Purchase Agreement (PPAs, 76.9–406.0 USD/MWh) y el volumen del Sistema Eléctrico Nacional Interconectado (SENI) provienen del Boletín Anual del Ministerio de Energía y Minas 2024 y son **reales**. Los datos por central del pool de 21 generadores, la lista fina de los 38 PPAs heredados de la Corporación Dominicana de Empresas Eléctricas Estatales (CDEEE) a las Empresas Distribuidoras de Electricidad (EDEs) y las curvas horarias de demanda y spot son **sintéticos calibrados dentro de los rangos oficiales** — la información contractual por central no es de acceso público detallado. En consecuencia, la cifra de **USD 1,150 millones (MM)/año** debe leerse como un **techo teórico** del espacio de optimización, no como un ahorro ejecutable: el modelo no captura compromisos de disponibilidad, restricciones de red, mantenimientos programados ni fricciones políticas. El valor del ejercicio está en la **metodología reproducible** y en la **cuantificación del delta contrato-spot** como espacio de política pública.
Repositorio abierto. El código del modelo de programación lineal entera mixta (Mixed-Integer Linear Programming, MILP), los datos calibrados, la capa de forecasting con eXtreme Gradient Boosting (XGBoost) y el dashboard Streamlit están disponibles en `github.com/leanmasterpymes/energia_optima`. Cualquier persona interesada — investigadores del sector eléctrico, reguladores, operadores, estudiantes avanzados de Investigación de Operaciones (IO) o ciencia de datos— puede clonar el repositorio para reproducir los resultados, sustituir los datos sintéticos por datos reales, cuestionar los supuestos o extender el modelo en las direcciones que proponga. Propuestas técnicas, observaciones a la formulación e issues en el repositorio son bienvenidos.

El problema que nadie cuantifica

En 2024 el Estado dominicano transfirió **RD$106,542.6 millones** (≈ USD 1,790 MM) en subsidio eléctrico. En los primeros siete meses de 2025 acumuló otros **RD$71,441 MM**. Desde 2003, el déficit tarifario pasa los **RD$170,000 MM**. Esa es la cifra que sale en los titulares.

La que no sale es la que me llevó a construir este modelo: el **precio monómico ponderado de compra de las EDEs** (EdeNorte, EdeSur, EdeEste) cerró 2024 en **150.81 USD/MWh** — 135.22 por contratos PPA y **205.34 por spot**, según el Boletín Anual de Generación y Gestión de Energía del Ministerio de Energía y Minas. Multiplicar la distancia entre esos dos precios por los 19,760 gigavatios-hora (GWh) que las EDEs compraron el año pasado da el tamaño real del espacio donde una decisión de compra mejor informada puede ahorrar cifras de nueve dígitos sin construir un solo kilómetro de red nueva.

El artículo presenta el modelo matemático, el código Python y el dashboard Streamlit que armé para responder una pregunta concreta: **dado un pool de 21 generadores del SENI con contratos PPA heredados, capacidades físicas, mínimos técnicos y una cuota renovable legalmente exigida, ¿cuál es el mix horario de compra que minimiza el costo del día cumpliendo todas las restricciones vigentes?**

Marco legal: no es un problema de compras públicas ordinario

Antes de escribir una sola restricción del modelo hay que entender bajo qué régimen operan las EDEs, porque no es el régimen general de compras públicas. Tras la liquidación de la CDEEE (Decreto 342-20, Ley 365-22), las tres distribuidoras compran energía bajo reglas propias:

- **Art. 5 de la Ley 340-06** excluye expresamente las compras de energía del régimen general de compras públicas.
- **Ley 125-01** (modificada por 186-07 y 365-22, reglamentada por Dec. 523-23) fija el marco: **Mercado Eléctrico Mayorista** con dos segmentos, **contratos (PPA)** y **spot** (costo marginal horario), y despacho por **orden de mérito** a cargo del **Organismo Coordinador del SENI (OC-SENI)**.
- **Ley 57-07** (reglamentada por Dec. 65-23, que derogó el Dec. 202-08) establece la meta del **25% de generación renovable** — meta no alcanzada: en 2024 las fuentes renovables representaron **23.32% de la capacidad instalada** y **≈ 17% de la generación real**.
- La **Comisión Liquidadora de la CDEEE (CLICDEEE) cedió 38 contratos** PPA a EDENORTE, EDESUR y EDEESTE en 2021. Esos contratos heredados imponen obligaciones tipo take-or-pay: la EDE paga la energía contratada aunque el despacho económico sugiera lo contrario.

De este marco salen las tres restricciones que no puedo relajar en el modelo: **cuota renovable**, **retiros mínimos heredados** y **licitación competitiva entre agentes del mercado mayorista**. Las otras son flexibles; estas no.

Formulación matemática: el problema como MILP

Conjuntos

- $G^{ren} \subseteq G$: generadores en el mercado mayorista (público, mixto, privado).
- $G^{her} \subseteq G$: horas del horizonte (24 h en el escenario base).
- $x_{g,t}^{PPA} \geq 0$: renovables (hidro, solar, eólica, biomasa).
- $x_{g,t}^{spot} \geq 0$: generadores con PPA heredado de la CDEEE.

Variables de decisión

- $y_{g,t} \in \{0,1\}$: MWh comprados por contrato al generador $y_{g,t}$ en la hora f_k .
- ℓ : MWh comprados en mercado spot.
- γ, λ : 1 si y_t está en línea en h_t , 0 en caso contrario.

Función objetivo

$$\min Z = \sum_{t \in T} \sum_{g \in G} (P_g^{PPA} \cdot x_{g,t}^{PPA} + P_t^{spot} \cdot x_{g,t}^{spot})$$

Restricciones

Balance de demanda:

$$\sum_g (x_{g,t}^{PPA} + x_{g,t}^{spot}) = D_t \quad \forall t$$

Capacidad física (disponibilidad horaria, con perfil para renovables):

$$x_{g,t}^{PPA} + x_{g,t}^{spot} \leq \overline{C}_{g,t} \cdot y_{g,t}$$

Mínimo técnico:

$$x_{g,t}^{PPA} + x_{g,t}^{spot} \geq C_g^{\min} \cdot y_{g,t}$$

Tope del contrato PPA:

$$x_{g,t}^{PPA} \leq \overline{Q}_{g,t}^{PPA}$$

Take-or-pay heredados (CDEEE → EDEs):

$$\sum_t x_{g,t}^{PPA} \geq Q_g^{\min,her} \quad \forall g \in G^{her}$$

Rampa inter-horaria:

$$|(x_{g,t}^{PPA} + x_{g,t}^{spot}) - (x_{g,t-1}^{PPA} + x_{g,t-1}^{spot})| \leq R_g$$

Cuota renovable (Ley 57-07):

$$\sum_t \sum_{g \in G^{ren}} (x_{g,t}^{PPA} + x_{g,t}^{spot}) \geq \rho \cdot \sum_t D_t$$

Reserva rodante:

$$\sum_g C_{g,t} \cdot y_{g,t} \geq (1+\sigma) \cdot D_t$$

Problema **MILP** — binarios d_t para mínimos técnicos y reserva, continuas para las compras. Se resuelve con el solver COIN-OR Branch and Cut (CBC), open-source, en fracciones de segundo para 21 generadores × 24 horas.

El código: formulación en PuLP

PuLP es la librería de Python que uso para escribir el problema en sintaxis declarativa (variables, función objetivo, restricciones). No resuelve — delega. Al llamar `prob.solve(pulp.PULP_CBC_CMD())` el problema se pasa al solver CBC externo, que aplica branch-and-bound y devuelve la solución óptima. Esta separación entre **lenguaje de modelado** (PuLP) y **solver** (CBC) es estándar en IO y permite cambiar a Gurobi, CPLEX o HiGHS modificando una sola línea si más adelante se necesita más velocidad.

```python
import pulp

prob = pulp.LpProblem("Compras_EDEs", pulp.LpMinimize)

x_ppa  = pulp.LpVariable.dicts("xPPA",  (G, T), lowBound=0)
x_spot = pulp.LpVariable.dicts("xSPOT", (G, T), lowBound=0)
y      = pulp.LpVariable.dicts("y",     (G, T), cat="Binary")

# Funcion objetivo
prob += pulp.lpSum(
    p_ppa[g]*x_ppa[g][t] + p_spot[t]*x_spot[g][t]
    for g in G for t in T
)

# Balance de demanda
for t in T:
    prob += pulp.lpSum(x_ppa[g][t] + x_spot[g][t] for g in G) == D[t]

# Capacidad + minimo tecnico
for g in G:
    for t in T:
        prob += x_ppa[g][t] + x_spot[g][t] <= disp[g][t] * y[g][t]
        prob += x_ppa[g][t] + x_spot[g][t] >= min_tec[g] * y[g][t]
        prob += x_ppa[g][t] <= cuota_ppa[g]

# Take-or-pay heredados
for g in G:
    if es_heredado[g]:
        prob += pulp.lpSum(x_ppa[g][t] for t in T) >= retiro_min[g]

# Cuota renovable (Ley 57-07)
prob += pulp.lpSum(
    x_ppa[g][t] + x_spot[g][t]
    for g in G if es_renovable[g] for t in T
) >= rho * sum(D.values())

# Reserva rodante
for t in T:
    prob += pulp.lpSum(disp[g][t]*y[g][t] for g in G) >= (1+sigma)*D[t]

prob.solve(pulp.PULP_CBC_CMD(msg=False))
```

(El código completo, los datos calibrados y el dashboard están en el repositorio indicado al inicio.)

La capa de Inteligencia Artificial (IA): forecasting para optimizar bajo incertidumbre

Un MILP con datos fijos resuelve un problema académico. En la operación real del SENI, el OC-SENI programa el día siguiente con demanda y precios **proyectados**, no observados. Si el modelo va a parecerse aunque sea un poco a la realidad operativa, el optimizador necesita un forecast acoplándolo — y ahí entra la capa de machine learning.

Construí un módulo (`src/forecast.py`) que entrena dos modelos **XGBoost** — uno para demanda horaria, otro para precio spot horario — sobre un histórico sintético de 180 días calibrado al SENI 2024. La salida (24 h del día siguiente) reemplaza los CSVs estáticos y alimenta directo al MILP.

Formulación del aprendizaje

XGBoost minimiza, sobre un ensemble de m_t árboles y_{t-24}, un objetivo regularizado:

$$\mathscr{L}(\phi) = \sum_{i=1}^{n} \ell(\hat{y}_i, y_i) + \sum_{k=1}^{K} \Omega(f_k), \qquad \Omega(f) = \gamma T + \tfrac{1}{2}\lambda \, \|w\|^2$$

donde y_{t-168} es el error cuadrático, $\bar{y}_{t,7d}$ el número de hojas del árbol, $\hat{y} \approx y$ sus pesos y `\gamma, \lambda` hiperparámetros de regularización. El gradiente boosting añade un árbol en cada iteración para corregir los residuos del ensemble previo.

Feature engineering

Para cada target `y_t` (demanda o spot en la hora `t`) construyo el vector de features:

$$x_t = [\, h_t,\ d_t,\ m_t,\ \mathbf{1}_{\text{finde}},\ \sin\tfrac{2\pi h_t}{24},\ \cos\tfrac{2\pi h_t}{24},\ \sin\tfrac{2\pi d_t}{7},\ \cos\tfrac{2\pi d_t}{7},\ y_{t-24},\ y_{t-168},\ \bar{y}_{t,7d}\,]$$

donde `h_t` es hora del día, `d_t` día de la semana, `m_t` mes, `y_{t-24}` el lag de mismo horario del día anterior, `y_{t-168}` el lag de misma hora-día-semana-anterior, y `\bar{y}_{t,7d}` la media móvil de 7 días por horario. Los senos/cosenos fuerzan al modelo a tratar la hora y el día como **cíclicos** (23→0 y 6→0 están cerca).

Código

```
from xgboost import XGBRegressor
from sklearn.metrics import mean_absolute_percentage_error

X_train, y_train = train[cols], train[target]
X_test,  y_test  = test[cols],  test[target]

model = XGBRegressor(
    n_estimators=400, max_depth=6, learning_rate=0.05,
    subsample=0.85, colsample_bytree=0.85,
    reg_lambda=1.0, reg_alpha=0.1,
    tree_method="hist", random_state=42,
)
model.fit(X_train, y_train)
mape = mean_absolute_percentage_error(y_test, model.predict(X_test))
```

Resultados sobre el test set (últimos 14 días, 336 h)

Dos métricas de evaluación: el **error porcentual absoluto medio** (Mean Absolute Percentage Error, MAPE) y la **raíz del error cuadrático medio** (Root Mean Squared Error, RMSE).

MODELO	MAPE	RMSE	TOP-3 FEATURES (GAIN)
Demanda (MWh)	**3.23 %**	121.6 MWh	`lag168` · `lag24` · `hora_sin`
Spot (USD/MWh)	**8.80 %**	23.4 USD/MWh	`hora` · `lag168` · `hora_cos`

La importancia de variables confirma lo que el dato grueso sugería: en la **demanda**, `lag168` (misma hora, semana anterior) domina con el 74% del gain normalizado — el consumo eléctrico tiene una periodicidad semanal fuerte. En el **spot** la cosa cambia: la hora del día pesa casi tanto como el lag semanal, porque el precio marginal responde sobre todo al pico nocturno 19–21 h, no al ritmo semanal.

Separación de responsabilidades: predicción ≠ optimización

Predicción y optimización son dos problemas matemáticamente distintos, y conviene separarlos con precisión antes de interpretar los resultados. Cada uno resuelve una pieza distinta del ciclo operativo del SENI:

- **Predicción (XGBoost)** minimiza un error de estimación sobre una variable observable. Formalmente, busca `\hat{y} \approx y` bajo una métrica como MAPE o RMSE. No toma decisiones — produce el mejor estimado del estado futuro del sistema (demanda horaria, precio spot).

- **Optimización (MILP + CBC)** minimiza una función objetivo económica sujeta a restricciones físicas y contractuales. Dada una realidad asumida conocida, determina la política óptima de compras. No predice — asume y decide.

La integración es unidireccional y acotada: **el despacho no puede ser mejor que el forecast que lo alimenta**. Un MILP resuelto con gap de optimalidad 0% sobre un forecast con 20% de error produce una política impecable para el día equivocado. Eso no es defecto del solver; es defecto del ojo que se le enseñó al modelo. Por eso el sistema integrado reporta **dos métricas separadas** — MAPE del forecast y gap del solver — y cualquier mejora operativa requiere atacar ambas en paralelo.

Esta separación reproduce, a escala reducida, la arquitectura real del OC-SENI: las Programaciones de Largo, Mediano y Corto Plazo consumen pronósticos de demanda y disponibilidad como insumo, y resuelven sobre ellos un despacho económico con restricciones físicas de la red. El valor de un modelo IO + IA no está en que la IA "optimice", sino en que el par acoplado **reemplaza supuestos estáticos por estimaciones realistas** del estado del sistema.

Cierre del lazo IO + IA

El pipeline completo es:

```
[historico sintético 180 d]
          │
          ▼
[feature engineering]
          │
          ▼
[XGBoost demanda]  [XGBoost spot]
          │                │
          └────────┬───────┘
                   ▼
      [forecast 24 h día siguiente]
                   │
                   ▼
   [MILP build_and_solve(gen, fc_dem, fc_spot, params)]
                   │
                   ▼
         [despacho óptimo esperado]
```

Con ese acople, pasar de "optimización con datos perfectos" a "optimización programada con forecast" es una línea de código. Es la pieza que convierte un modelo académico en una herramienta con relación con la operación real.

Del demo a la operación: re-entrenamiento con ventana rodante

La implementación actual parte de un histórico fijo de 180 días sintéticos generados una sola vez con semilla controlada. Es suficiente para demostrar la integración y reproducir resultados, pero insuficiente para operación real. En un despliegue productivo sobre datos del OC-SENI, el flujo debería operar con **ventana rodante y re-entrenamiento periódico**:

```
cada día T:
  1. Incorporar al histórico las 24 mediciones del día T-1
     (demanda observada + spot publicado por el OC-SENI)
  2. Re-entrenar los dos XGBoost con la ventana actualizada
  3. Emitir forecast de las 24 h del día T+1
  4. Alimentar al MILP y generar el despacho programado
```

El tamaño de la ventana (60 / 90 / 180 días) y la frecuencia de re-entrenamiento (diaria, semanal) son decisiones de ingeniería con trade-offs explícitos: ventanas cortas capturan cambios estructurales rápido — entrada de nuevas centrales, vencimientos de PPA, cambio regulatorio — a costa de mayor varianza del modelo; ventanas largas son más estables pero reaccionan tarde a cambios de régimen. Para el SENI dominicano con 605 megavatios (MW) renovables entrando en 2026 y vencimiento de las barcazas a fin de año, una ventana de ~90 días con re-entrenamiento semanal probablemente domine en MAPE operativo a re-entrenamiento diario sobre 180 días — pero esa elección se valida midiendo en backtesting, no a priori.

Dashboard Streamlit: viendo el óptimo en movimiento

Un reporte estático de resultados no me servía. Quería poder mover la cuota renovable del 25% al 35% en vivo, ver cómo el modelo reemplaza térmicas caras por renovables, y discutir esa transición con alguien en la misma pantalla. Así que monté un dashboard Streamlit sobre el modelo: herramienta de análisis de sensibilidad, no reporte. Los sliders ajustan cuota renovable, reserva rodante, aplicabilidad de take-or-pay, y multiplicadores de demanda y precio spot. La optimización re-corre en tiempo real y actualiza cuatro vistas: despacho horario, mix tecnológico, costos PPA vs spot y detalle por generador.

La primera vez que alguien sube la cuota renovable del 25% al 35%, el costo total sube — pero el **precio promedio por MWh cae**, porque el modelo reemplaza térmicas caras (fuel oil, emergencia) por solares y eólicos nuevos con PPAs en el rango 78–92 USD/MWh. Esa es la conversación que ningún reporte estático puede tener.

Resultados del escenario base

Con los datos sintéticos calibrados al SENI 2024 (pool de 21 generadores agregados, demanda diaria 71,070 MWh, pico nocturno 3,820 MW) y cuota renovable al 25%:

KPI	ESCENARIO OPTIMIZADO	REAL 2024 (MINISTERIO)	DELTA
Precio promedio (USD/MWh)	**106.48**	150.81	**−44.33**
% vía PPA	99.9%	78%	+22 pp
% renovable	32.3%	~17% (generación)	+15 pp
Costo día (USD)	7,567,504	~10,720,000	**−3,152,000**

Ahorro potencial anualizado: ≈ USD 1,140 millones.

Lo que más me llamó la atención al correr el primer escenario es que el óptimo privilegia PPAs a 99.9% y deja el spot para un 0.1% residual. En otras palabras: si hubiera libertad de rediseñar la canasta, el spot como mercado de cobertura sería marginal — casi todo el trabajo lo puede hacer el contrato bilateral bien estructurado. El modelo llega a esa conclusión privilegiando los PPAs baratos (hidro EGEHID a 76.9, solar nuevo a 78.2, eólico nuevo a 91.9, Itabo a 94.3), evitando el spot nocturno (que supera los 280 USD/MWh en el pico de demanda entre 19–21 h) y dejando a Karpowership (406 USD/MWh) sin despachar.

Ese último punto merece una mirada crítica: en la realidad Karpowership se mantiene **no por un PPA heredado de la CDEEE**, sino por un **contrato de emergencia post-cesión** adjudicado en agosto de 2022 (EDES-LPI-02-202), al que después se le sumó una tercera barcaza por decreto de emergencia en octubre de 2025. Las dos barcazas originales **vencen a finales de 2026**, y el informe técnico conjunto de la Universidad Autónoma de Santo Domingo (UASD) + Academia de Ciencias del 7 de marzo de 2026 recomienda explícitamente **no renovar**. La brecha entre el óptimo matemático y lo ejecutable es el espacio real de política pública — y en este caso concreto, es una decisión con fecha de vencimiento.

Limitaciones honestas

Lo que el modelo **no** hace, en orden de importancia:

1. **Precios por central**: el Boletín del Ministerio de Energía y Minas publica ponderados del sistema, no los precios contractuales exactos por central. Calibré dentro del rango reportado (76.9–406.0 USD/MWh), pero los precios del dataset no son los contractuales reales.
2. **Lista de los 38 PPAs heredados**: sigue sin publicarse detalladamente (MW, contraparte, precio, vencimiento) cinco años después de la cesión CLICDEEE→EDEs de 2021. El modelo los trata como un **bloque homogéneo** con retiros mínimos sintéticos, pero en la realidad no todos son iguales: los contratos renovables heredados suelen tener take-or-pay más suave (curtailment compensable), mientras

que los térmicos combinan pago por capacidad + energía. Además, la frontera "heredado pre-2021" se ha ido desdibujando con las licitaciones post-cesión (EDES-LPI-02-202, SIE-108-2022-LCE, EDES-LPI-NG-04-2023, EDES-LP-NGR-01-2025) — un modelo riguroso debería separar los conjuntos y tratarlos con restricciones distintas.

3. **Cuota renovable**: se modela como restricción dura sistémica; en la práctica no existe una cuota obligatoria específica a EDEs bajo la Ley 57-07, la meta del 25% es indicativa.
4. **Horizonte 24 h**: un modelo semanal o anual capturaría estacionalidad hidrológica, mantenimientos programados y curvas de disponibilidad del gas natural licuado (Liquid Natural Gas, LNG).
5. **Red y pérdidas de transmisión**: el modelo asume nodo único. Extensión natural: flujo óptimo de potencia (Optimal Power Flow, OPF) con la Empresa de Transmisión Eléctrica Dominicana (ETED) y restricciones de flujo.

Qué sigue

El mix 2026–2028 cambia materialmente el modelo

El modelo que presento acá es una foto del SENI 2024. Los próximos 24 meses lo van a mover bastante — incorpora activos que el modelo actual no representa:

- **605 MW renovables con sistemas de almacenamiento en baterías (Battery Energy Storage System, BESS)** adjudicados preliminarmente en la licitación EDES-LP-NGR-01-2025 (abril 2026), a un precio promedio ponderado de **USD 0.108 por kilovatio-hora (kWh)** — muy por debajo del ponderado real 2024.
- **~414 MW térmicos nuevos** entrando al SENI durante 2026 (Generadora San Felipe I, Energía 2000) que desplazan generación cara.
- **Vencimiento de las barcazas Karpowership (≥400 MW a 406 USD/MWh)** a fines de 2026, con presión pública para no renovar.

La extensión natural es separar los PPAs en dos conjuntos — **heredados pre-2021** (con take-or-pay duro) vs **nuevos EDEs 2022-2026** (con cláusulas distintas) — y marcar los que tienen fecha de vencimiento dentro del horizonte de simulación.

Extensiones metodológicas en el backlog

- **Estocasticidad**: agregar incertidumbre en demanda y perfil renovable (programación estocástica en dos etapas o robusta), aprovechando ya el forecast XGBoost como media del escenario.
- **Horizonte rodante**: resolver diariamente con ventana móvil de 7 días, re-entrenar el forecast y re-optimizar con información nueva del OC-SENI.
- **Redes neuronales de memoria a largo plazo (Long Short-Term Memory, LSTM) / Transformers para spot**: MAPE 8.8% de XGBoost es razonable para un

baseline; un modelo secuencial debería bajarlo capturando mejor los saltos nocturnos.

Para cerrar

Lo que más me interesa de este ejercicio no es la cifra del ahorro — es que el marco es reproducible. Si alguien con acceso a la lista real de los 38 PPAs heredados sustituye el CSV sintético por el contractual y corre `python -m src.model`, el número deja de ser ilustrativo y pasa a ser auditable. La matemática, el código y los supuestos están abiertos; el cuello de botella para llevar esto a decisión operativa es el acceso a los datos contractuales, y esa pieza depende de política pública, no de más líneas de código.

Referencias normativas y de datos

- Ley 125-01 General de Electricidad (modificada por 186-07, 365-22; Dec. 523-23).
- Ley 57-07 de Incentivo a Fuentes Renovables (modif. 115-15; Dec. 65-23).
- Ley 340-06 Art. 5 — régimen especial de compras de energía.
- Decreto 342-20, Ley 365-22 — liquidación CDEEE y creación del Consejo Unificado de Empresas Distribuidoras (CUED).
- Boletín Anual del Ministerio de Energía y Minas 2024 y boletín mensual oct-2025 — precios PPA vs spot.
- OC-SENI — Organismo Coordinador del SENI, despacho por mérito.
- Resolución SIE-040-2013-REG de la Superintendencia de Electricidad (SIE) — umbral de Usuario No Regulado (UNR) vigente (1 MW).

Repositorio: github.com/leanmasterpymes/energia_optima · PuLP + CBC · Streamlit · Python 3.12